

Mendelova univerzita v Brně
Provozně ekonomická fakulta

Klasifikace sentimentu, shlukování témat a vyhledávání podobných hotelových recenzí

Semestrální projekt

Vedoucí práce:
doc. Ing. František Dařena, Ph.D.

Bc. Jan Dub
Bc. David Krčmář

Brno 2026

Abstract

Dub, J.; Krčmář, D. Sentiment Classification, Topic Clustering and Similarity Search in Hotel Reviews. Semester project. Mendel University in Brno, 2026.

This semester project presents a compact end-to-end text-mining pipeline for hotel reviews from the Kaggle dataset *515K Hotel Reviews Data in Europe*. The work validates and summarizes the original CSV file, preprocesses review text, trains and compares three classical classifiers, evaluates chi-square feature selection, clusters negative reviews with K-Means, and builds a TF-IDF retrieval module with cosine similarity. The dataset contains 515,738 reviews and 17 columns. On a 50,000-review development sample, the best sentiment configuration combines **TF-IDF with unigrams and bigrams**, **SelectKBest(chi2, k=5000)** and **Linear SVM**, reaching **macro F1 = 0.8120** and **accuracy = 95.03%**. Negative-review clustering is interpretable but only weakly separated, with the best result at **k = 7** and **silhouette score = 0.0100**. Retrieval works well for specific multi-word queries and degrades for generic queries. The report discusses both the practical usefulness and the limits of classical text-mining methods on noisy user-generated review data.

Key words: text mining, hotel reviews, sentiment classification, clustering, information retrieval, TF-IDF, Linear SVM

Abstrakt

Dub, J.; Krčmář, D. Klasifikace sentimentu, shlukování témat a vyhledávání podobných hotelových recenzí. Semestrální projekt. Mendelova univerzita v Brně, 2026.

Tento semestrální projekt představuje kompaktní end-to-end text-mining pipeline nad hotelovými recenzemi z Kaggle datasetu *515K Hotel Reviews Data in Europe*. Práce ověřuje a shrnuje původní CSV soubor, předzpracovává text recenzí, trénuje a porovnává tři klasické klasifikační modely, vyhodnocuje výběr atributů pomocí chi-kvadrát testu, shlukuje negativní recenze metodou K-Means a buduje retrieval modul založený na TF-IDF a cosine similarity. Dataset obsahuje 515 738 recenzí a 17 sloupců. Na development vzorku o velikosti 50 000 recenzí dosáhla nejlepší konfigurace sentiment klasifikace ve složení **TF-IDF s unigramy a bigramy**, **SelectKBest(chi2, k=5000)** a **Linear SVM** hodnot **macro F1 = 0,8120** a **accuracy = 95,03 %**. Clustering negativních recenzí je interpretovatelný, ale jen slabě separovaný; nejlepší konfigurace vyšla pro **k = 7** se **silhouette score = 0,0100**. Retrieval funguje dobře pro konkrétní víceslovné dotazy a ztrácí kvalitu

u obecných formulací. Report diskutuje praktický přínos i limity klasických text-mining metod na hlučných uživatelských recenzích.

Klíčová slova: text mining, hotelové recenze, klasifikace sentimentu, clustering, information retrieval, TF-IDF, Linear SVM

Obsah

1	Úvod a motivace	8
2	Cíl práce a výzkumné otázky	9
2.1	Hlavní cíle	9
2.2	Výzkumné otázky	9
3	Dataset	10
3.1	Zdroj a struktura dat	10
3.2	Kvalita dat a praktická omezení	10
3.3	Rozdělení skóre recenzí	10
3.4	Pracovní režim	11
4	Data preprocessing	12
4.1	Tvorba textových atributů	12
4.2	Čisticí pipeline	12
4.3	Reprezentace textu a labely	13
5	Sentiment classification	14
5.1	Použité modely a evaluační nastavení	14
5.2	Baseline výsledky bez feature selection	14
5.3	Interpretace nejlepší baseline	14
6	Feature selection	16
6.1	Metoda a experimentální nastavení	16
6.2	Porovnání konfigurací	16
6.3	Nejdůležitější termy pro sentiment	16
7	Clustering negativních recenzí	18
7.1	Vstupní data a metoda	18
7.2	Volba počtu clusterů	18
7.3	Interpretace finálních clusterů	18
7.4	Slabé stránky clusteringu	19
8	Information retrieval	20
8.1	Návrh retrieval modulu	20
8.2	Ukázkové dotazy	20
8.3	Kvalitativní zhodnocení relevance	20
9	Diskuse	22
9.1	Co fungovalo nejlépe	22
9.2	Co bylo problematické	22
9.3	Limity práce	22

9.4 Future work	22
10 Závěr	24
11 Použitá literatura	25

Seznam použitých pojmů

- ***TF-IDF***: vážená reprezentace textu, která zvýrazňuje termy důležité pro konkrétní dokument a potlačuje příliš častá slova v celé kolekci.
- ***n-gram***: posloupnost n tokenů; v této práci porovnáváme unigramy a kombinaci unigramů s bigramy.
- ***Linear SVM***: lineární Support Vector Machine, tedy klasifikátor vhodný pro řídké textové reprezentace s vysokým počtem atributů.
- ***Chi-square feature selection***: metoda výběru atributů podle závislosti mezi termem a cílovou třídou.
- ***K-Means***: clustering algoritmus, který rozděluje dokumenty do předem zadaného počtu clusterů podle vzdálenosti od centroidů.
- ***Silhouette score***: interní metrika clusteringu hodnotící kompaktnost clusteru a jeho oddělení od ostatních clusterů.
- ***Cosine similarity***: míra podobnosti dvou vektorů podle úhlu mezi nimi; standardní volba pro porovnávání TF-IDF reprezentací.

1 Úvod a motivace

Hotelové recenze jsou vhodným příkladem reálných textových dat, na nichž lze ukázat hlavní úlohy text miningu v jedné společné pipeline. Každá recenze kombinuje volný text, číselné skóre a doplňující metadata. Tato kombinace umožňuje současně řešit klasifikaci sentimentu, tematické shlukování i vyhledávání podobných dokumentů.

Praktická motivace je dvojí. Zaprvé hotelové recenze představují obchodně důležitý zdroj zpětné vazby pro provozovatele ubytování i agregátory typu Booking.com. Zadruhé jde o dataset s realistickým množstvím šumu: obsahuje placeholdery typu **No Negative**, velmi krátké zápisy, různou délku recenzí i nevyvážené rozdělení výsledných tříd. Projekt je proto vhodný nejen pro demonstraci funkčních metod, ale i pro otevřenou diskusi jejich limitů.

Z pohledu předmětu práce pokrývá reprezentaci textu, preprocessing, klasifikaci, feature selection, clustering i information retrieval. Místo jedné izolované úlohy tak vzniká konzistentní text-mining projekt se sdíleným datasetovým základem a společným vyhodnocením.

2 Cíl práce a výzkumné otázky

Cílem práce je navrhnout a implementovat kompaktní text-mining pipeline pro analýzu hotelových recenzí a ověřit, které klasické metody fungují na tomto typu dat nejlépe.

2.1 Hlavní cíle

1. připravit a zdokumentovat dataset hotelových recenzí,
2. vytvořit společnou textovou reprezentaci vhodnou pro strojové učení,
3. natrénovat a porovnat několik modelů sentiment klasifikace,
4. vyhodnotit vliv výběru atributů pomocí `SelectKBest(chi2)`,
5. identifikovat hlavní tematické okruhy v negativních recenzích pomocí clusteringu,
6. vytvořit jednoduchý retrieval modul vracející podobné recenze pro zadaný dotaz.

2.2 Výzkumné otázky

1. Který ze tří klasických modelů (`MultinomialNB`, `LogisticRegression`, `LinearSVC`) dosahuje na hotelových recenzích nejlepší kvality?
2. Pomůže výběr atributů pomocí `SelectKBest(chi2)` oproti čistému TF-IDF baseline?
3. Jaká témata dominují negativním recenzím a nakolik jsou výsledné clusterly interpretovatelné?
4. Nakolik dobře funguje retrieval založený na TF-IDF a cosine similarity pro konkrétní a obecné dotazy?

3 Dataset

3.1 Zdroj a struktura dat

Primárním zdrojem je Kaggle dataset *515K Hotel Reviews Data in Europe* od Jiashena Liu. Pracujeme s originálním souborem `Hotel_Reviews.csv`, který je uložen v lokální struktuře projektu v adresáři `data/raw/`. Dataset obsahuje textová pole `Positive_Review` a `Negative_Review`, dále číselné skóre `Reviewer_Score` a pomocná metadata, například `Hotel_Name`, `Average_Score`, `Tags` nebo zeměpisnou polohu hotelu.

Tabulka 1: Základní charakteristika datasetu

Položka	Hodnota
Zdroj	Kaggle: <i>515K Hotel Reviews Data in Europe</i>
Hlavní soubor	<code>Hotel_Reviews.csv</code>
Počet řádků	515 738
Počet sloupců	17
Klíčové atributy	<code>Positive_Review</code> , <code>Negative_Review</code> , <code>Reviewer_Score</code> , <code>Hotel_Name</code> , <code>Tags</code>
Datové typy	textová pole typu <code>object</code> , skóre typu <code>float64</code> , některé počty typu <code>int64</code>
Chybějící hodnoty	v textových polích a skóre 0; u <code>lat/lng</code> celkem 3 268 hodnot
Rozsah <code>Reviewer_Score</code>	2.5 až 10.0
Průměr / medián skóre	8.3951 / 8.8


3.2 Kvalita dat a praktická omezení

Dataset je rozsáhlý, ale nikoli čistý. Velká část recenzí používá placeholdery typu `No Negative` nebo `No Positive`. V ověřeném lokálním snapshotu se vyskytuje 152 663 hodnot typu `No Negative` a 37 791 hodnot typu `No Positive`. Kromě toho se objevují i krátké pseudo-negativní výrazy jako `No complaints`, `Everything was perfect` nebo pouze `Breakfast`, které nejsou technicky placeholder, ale obsahově komplikují další zpracování.

Dalším omezením je výrazně pozitivní rozdělení skóre. Nejčastější hodnota v celém datasetu je 10.0, která se vyskytuje 115 853krát, zatímco spodní část škály je zastoupena podstatně méně. To je důležité pro návrh labelů i pro interpretaci accuracy, která sama o sobě nestačí.

3.3 Rozdělení skóre recenzí

Rozdělení `Reviewer_Score` ukazuje obrázek 1. Vysoká koncentrace hodnocení v intervalu 8.3 až 10.0 potvrzuje, že jde o dataset s přirozeným pozitivním biasem.



Obrázek 1: Rozdělení hodnot `Reviewer_Score` v celém datasetu

3.4 Pracovní režim

Pro samotné experimenty jsme nepoužívali plný dataset ve všech krocích. Pro rychlé iterace a ladění se ukázal jako praktický vzorek 20 000 až 50 000 záznamů, zatímco plný dataset zůstává vhodný spíše jako volitelný benchmark. Tento kompromis odpovídá školnímu charakteru projektu: hlavním cílem je porovnání metod a interpretace výsledků, nikoli maximalizace výkonu za cenu dlouhých běhů a vyšších paměťových nároků.

4 Data preprocessing

4.1 Tvorba textových atributů

V projektu vytváříme tři společné textové varianty:

- **review_text**: spojení pozitivní a negativní části recenze,
- **negative_text**: pouze negativní část recenze,
- **positive_text**: pouze pozitivní část recenze.

Pro sentiment klasifikaci se jako nejlepší volba ukázalo **review_text**, protože kombinuje oba póly recenze a dává modelu nejvíce kontextu. Pro clustering jsme naopak používali **negative_text**, kde jsou témata problémů čitelnější.

4.2 Čisticí pipeline

Před samotnou reprezentací proběhly následující kroky:

1. náhrada placeholderů v polích **Positive_Review** a **Negative_Review** prázdným textem,
2. odstranění prázdných vybraných textových polí,
3. převod na malá písmena,
4. odstranění nealfabetických znaků,
5. normalizace mezer,
6. odstranění záznamů, které zůstaly prázdné i po cleaningu.

Na development vzorku o velikosti 50 000 řádků vedl binární label filter a preprocessing k následujícímu průchodu daty:

Tabulka 2: Průchod daty po labelingu a preprocessingu

Krok	Počet řádků
Načtený development sample	50 000
Po binárním labelingu	35 553
Po odfiltrování prázdného textového pole	35 520
Po final cleaningu	35 519
Train split	28 415
Test split	7 104

4.3 Reprezentace textu a labely

Finální baseline pro klasifikaci používá TF-IDF reprezentaci z knihovny scikit-learn. Testovali jsme unigramy i kombinaci unigramů s bigramy; lepší se ukázala druhá varianta. Zvolená konfigurace byla:

- `ngram_range = (1, 2)`,
- `min_df = 5`,
- `max_df = 0.9`,
- `max_features = 50000`,
- anglický seznam stop slov ze scikit-learn.

Sentiment labely byly vytvořeny binárně:

- `Reviewer_Score <= 5.0` → negative,
- `Reviewer_Score >= 8.0` → positive,
- střední pásmo bylo z klasifikace vynecháno.

Tento návrh záměrně zvyšuje separaci tříd, ale zároveň zmenšuje datovou základnu. Po filtrování zůstalo na development vzorku 32 502 pozitivních a 3 017 negativních recenzí, což potvrzuje výraznou nevyváženost tříd.

5 Sentiment classification

5.1 Použité modely a evaluační nastavení

Porovnávali jsme tři klasické modely vhodné pro řídké textové reprezentace:

- Multinomial Naive Bayes,
- Logistic Regression,
- Linear SVM.

Pro rozdělení dat byl použit stratifikovaný train/test split v poměru 80/20. Kvůli nevyváženosti tříd sledujeme kromě accuracy také macro precision, macro recall a macro F1. To je důležité zejména proto, že vysoká accuracy může vznikat i při systematickém zanedbávání menšinové negativní třídy.

5.2 Baseline výsledky bez feature selection

Tabulka 3 shrnuje výsledky baseline konfigurace nad `review_text` s TF-IDF unigramy a bigramy.

Tabulka 3: Výsledky sentiment klasifikace bez feature selection

Model	Macro prec.	Macro rec.	Macro F1	Acc.
Linear SVM	0.8717	0.7602	0.8039	0.9481
Logistic Regression	0.9152	0.6982	0.7612	0.9447
Multinomial Naive Bayes	0.9476	0.5926	0.6374	0.9303

Linear SVM skončil v baseline první. Logistic Regression zůstává konkurenceschopná, ale zaostává hlavně v macro recall. Naive Bayes sice drží slušnou accuracy, avšak na minoritní negativní třídě ztrácí, což se projeví výrazně slabším macro F1.

5.3 Interpretace nejlepší baseline

Pro nejlepší baseline model (Linear SVM) ukazuje confusion matrix následující chování:

Tabulka 4: Confusion matrix pro baseline Linear SVM

Skutečná / predikovaná třída	Negative	Positive
Negative	321	281
Positive	88	6 413

Model tedy velmi dobře rozpoznává pozitivní recenze, ale část negativních recenzí stále přiřazuje do pozitivní třídy. To odpovídá charakteru dat: negativní třída je menší, lexikálně méně homogenní a častěji obsahuje krátké či smíšené formulace.

6 Feature selection

6.1 Metoda a experimentální nastavení

V další fázi jsme nad stejnou TF-IDF reprezentací aplikovali `SelectKBest(chi2)`. Cílem bylo ověřit, zda výběr atributů dokáže odstranit část šumu, zlepšit generalizaci a zároveň nabídnout lépe interpretovatelné termy pro sentiment.

Testovali jsme hodnoty $k \in \{0, 5000, 10000, 20000, 30000\}$, kde $k = 0$ znamená baseline bez feature selection. U vyšších hodnot se ukázalo, že skutečný počet aktivních atributů po vektorizaci je pouze 15 266; proto konfigurace s $k = 20000$ a $k = 30000$ fakticky vracejí všechny atributy a reprodukuje baseline.

6.2 Porovnání konfigurací

Tabulka 5: Vliv feature selection na nejlepší model (Linear SVM)

k	Macro F1	Accuracy
0	0.8039	0.9481
5 000	0.8120	0.9503
10 000	0.8032	0.9479
20 000	0.8039	0.9481
30 000	0.8039	0.9481

Nejlepší výsledek vyšel pro $k = 5000$. Oproti baseline se macro F1 zlepšilo o 0.0082 a accuracy o 0.0023. Nárůst není dramatický, ale je konzistentní a dostatečný pro to, abychom tuto konfiguraci zvolili jako finální variantu pro report.

6.3 Nejdůležitější termy pro sentiment

Feature selection pomohla nejen výkonu, ale i interpretaci. Pro nejlepší konfiguraci (Linear SVM + $k = 5000$) se mezi nejsilnějšími indikátory objevily následující termy:

Tabulka 6: Výběr výrazných sentiment termů

Pozitivní sentiment	Negativní sentiment
great	dirty
lovely	worst
fantastic	shabby
loved	poor
perfect	tired
amazing	unhelpful
good value	rude
friendly helpful	horrible

Termy mají dobrou sémantickou interpretovatelnost a potvrzují, že klasické lineární modely nad TF-IDF pro tento typ dat dávají smysluplný signál.

7 Clustering negativních recenzí

7.1 Vstupní data a metoda

Clustering jsme prováděli nad polem `negative_text`, protože právě zde lze nejlépe identifikovat opakující se typy problémů. Z development vzorku 20 000 recenzí zůstalo po odstranění prázdných a neinformativních textů 14 069 dokumentů. Použili jsme TF-IDF s unigramy a bigramy a následně algoritmus K-Means z knihovny scikit-learn.

7.2 Volba počtu clusterů

Testovali jsme hodnoty $k = 5, 6, 7, 8, 9$. Výsledky shrnuje tabulka 7.

Tabulka 7: Porovnání clusteringu pro různé hodnoty k

k	Silhouette score	Min. velikost clusteru	Max. velikost clusteru
5	0.0075	168	9 677
6	0.0088	171	7 968
7	0.0100	346	7 036
8	0.0090	170	7 138
9	0.0098	206	6 112

Nejlepší volba podle silhouette score je $k = 7$. Absolutní hodnota této metriky je však velmi nízká, takže výsledek je potřeba chápat opatrně: clustery jsou interpretovatelné, ale nikoli ostře oddělené.

7.3 Interpretace finálních clusterů

Pro nejlepší konfiguraci jsme clustery ručně pojmenovali podle top termů a reprezentativních recenzí:

Tabulka 8: Ruční interpretace clusterů pro $k = 7$

Cluster	Velikost	Interpretace
0	7 036	misc short or mixed complaints
1	604	very small room
2	1 197	breakfast quality and inclusion
3	612	small outdated rooms
4	346	expensive extras
5	3 311	room comfort and maintenance
6	963	staff and reception problems

Obsahově nejčistší jsou clustery zaměřené na malý pokoj, drahé doplňky, snídani nebo problémy se staffem. Slabší je naopak největší cluster, který zachycuje směs krátkých, obecných nebo jen částečně negativních zápisů.

7.4 Slabé stránky clusteringu

Nízké silhouette score a existence velkého „misc“ clusteru přímo souvisí s kvalitou vstupních textů. V datech zůstávají krátké nebo pseudo-negativní formulace typu **No failings**, **No complaints**, **Everything was perfect**, **Breakfast** nebo **Expensive**. Tyto výrazy snižují tematickou čistotu clusterů a zkreslují centroidy. Clustering zde proto vnímáme především jako exploratorní nástroj pro shrnutí častých problémů, nikoli jako finální segmentaci zákazníků.

8 Information retrieval

8.1 Návrh retrieval modulu

Retrieval modul využívá stejný princip jako klasifikační reprezentace, tentokrát však nad polem `review_text`. Na development vzorku 20 000 recenzí zůstalo po cleaningu 19 985 dokumentů. Finální TF-IDF index má rozměr $19\,985 \times 21\,242$ a vyhledávání probíhá pomocí cosine similarity.

8.2 Ukázkové dotazy

Připravili jsme šest dotazů, které pokrývají jak konkrétní problémy, tak obecné formulace:

- dirty room and noisy street,
- friendly staff and great location,
- small bathroom and old furniture,
- excellent breakfast and comfortable bed,
- slow wifi and poor service,
- good hotel.

8.3 Kvalitativní zhodnocení relevance

Tabulka 9: Kvalitativní hodnocení retrieval dotazů

Dotaz	Hodnocení	Poznámka
friendly staff and great location	strong	velmi přesné nebo téměř přesné shody
small bathroom and old furniture	strong	vrací starý nábytek, staré koupelny i malé pokoje
excellent breakfast and comfortable bed	strong	dobré pokrytí snídaně i komfortu postele
dirty room and noisy street	mixed	dobře zachytí hluk, ale už méně špínu
slow wifi and poor service	mixed	silný signál pro wifi, slabší pro service
good hotel	weak	příliš obecný dotaz vrací boilerplate pozitivní fráze

Retrieval funguje nejlépe tehdy, když dotaz obsahuje konkrétní vlastnosti hotelového zážitku. U obecných dotazů model přirozeně preferuje velmi krátké a časté pozitivní fráze, což snižuje užitečnost výsledků.

9 Diskuse

9.1 Co fungovalo nejlépe

Nejstabilnější částí celé pipeline byla sentiment klasifikace. Už čistý TF-IDF baseline s Linear SVM poskytl macro F1 přes 0.80 a feature selection pomocí `SelectKBest(chi2, k=5000)` přinesla další, byť nikoli dramatické zlepšení. To potvrzuje, že pro tento typ dat jsou lineární modely nad řídkou reprezentací stále velmi silnou a dobře interpretovatelnou volbou.

Pozitivně hodnotíme také retrieval modul. Pro konkrétní víceslovné dotazy vrací smysluplné a snadno interpretovatelné výsledky bez nutnosti používat složitější embeddingové modely.

9.2 Co bylo problematické

Hlavním problémem datasetu je šum. Kromě explicitních placeholderů zůstávají v datech krátké, obsahově nejednoznačné nebo pouze formálně negativní zápisy. Tento šum má přímý dopad zejména na clustering, kde vede k nízké separaci clusterů a ke vzniku jednoho dominantního „misc“ clusteru.

Druhým problémem je nevyváženost tříd po binárním labelingu. Accuracy u klasifikace je velmi vysoká, ale bez macro metrik by snadno zakryla fakt, že model má na negativní třídě stále podstatně slabší recall než na třídě pozitivní.

9.3 Limity práce

- většina experimentů byla prováděna na development vzorcích 20 000 až 50 000 řádků, nikoli na plném datasetu,
- retrieval byl hodnocen kvalitativně, bez ručně anotovaného relevance benchmarku,
- clustering byl interpretován ručně a bez externí ground truth,
- preprocessing používá jednoduché čištění bez lemmatizace, stemmingu nebo transformerových embeddingů.

9.4 Future work

Přirozeným pokračováním projektu by bylo:

- rozšířit slovník placeholderů a filtrovat krátké pseudo-negativní fráze cíleněji,
- otestovat plný dataset nebo alespoň větší reportový vzorek kolem 100 000 dokumentů,
- porovnat K-Means s NMF nebo topic modelingem,
- rozšířit retrieval o BM25 nebo sentence embeddings,

-
- zkusit vážení tříd nebo cílený sampling pro zlepšení recall negativní třídy.

10 Závěr

Práce ukázala, že i klasické text-mining metody dokážou na hotelových recenzích podat solidní a dobře interpretovatelné výsledky. Po ověření a vyčištění datasetu jsme vytvořili jednotnou pipeline pro reprezentaci textu, sentiment klasifikaci, feature selection, clustering a retrieval.

Nejlepší klasifikační konfigurace využívá `review_text`, TF-IDF s unigramy a bigramy, `SelectKBest(chi2, k=5000)` a Linear SVM. Tato varianta dosáhla macro $F1 = 0.8120$ a accuracy = 95.03 %. Feature selection se ukázala jako přínosná, byť její efekt není velký. Clustering negativních recenzí přinesl užitečná tematická shrnutí, zejména pro malé pokoje, snídani, drahé doplňky nebo problémy se staffem, avšak při nízké vnitřní separaci clusterů. Retrieval modul potvrdil, že TF-IDF a cosine similarity jsou pro konkrétní dotazy stále prakticky použitelné.

Celkově projekt splnil zamýšlený cíl: na jednom realistickém datasetu ukázal kompletní text-mining workflow, jeho silné stránky i limity. Výsledky jsou dostatečně konkrétní pro report i prezentaci a zároveň vytvářejí prostor pro další rozšíření.

11 Použitá literatura

1. Liu, J. *515K Hotel Reviews Data in Europe*. Kaggle dataset.
Dostupné z: <https://www.kaggle.com>
Dataset path: `datasets/jiashenliu/515k-hotel-reviews-data-in-europe`
2. Pedregosa, F. a kol. Scikit-learn: Machine Learning in Python. *Journal of Machine Learning Research*, 12, 2011, s. 2825–2830.
3. Manning, C. D.; Raghavan, P.; Schütze, H. *Introduction to Information Retrieval*. Cambridge University Press, 2008.